반도체 수율 극대화를 위한 신뢰성 기반의 미세 결함 탐지 시스템 구축

CBAM Attention과 Entropy-based Uncertainty Filtering을 활용한 준지도 학습 고도화

정원준 | University of Wisconsin-Madison | Computer Science & Data Science
willjung0726@gmail.com

---

1. Executive Summary

반도체 공정 미세화(Tech Scaling)가 가속화됨에 따라, 웨이퍼 수율 관리는 제조 경쟁력을 결정짓는 핵심 요소로 부상하였다. 제조 공정 중 발생하는 결함 패턴을 조기에 탐지하고 분류하는 ADC(Automatic Defect Classification) 시스템은 수율 저하의 원인을 규명하는 데 필수적이다. 그러나 현업 데이터는 극심한 클래스 불균형과 라벨링 비용 문제를 안고 있으며, 특히 회로 단선을 유발하는 치명적 결함인 'Scratch'는 웨이퍼 배경 노이즈와 구분이 어려운 미세한 선형 패턴으로 인해 기존 딥러닝 모델로도 탐지가 어려운 난제로 꼽힌다.

본 프로젝트는 제한된 라벨 데이터 환경에서 이러한 미세 결함 탐지 성능을 극대화하기 위해, 단계적인 모델 고도화 과정을 거쳐 **신뢰성 기반의 준지도 학습(Reliability-Aware Semi-supervised Learning)** 파이프라인을 구축하였다. 연구진은 일반적인 오토인코더 기반의 준지도 학습(Phase 7)이 미세 결함의 국소적 특징(Local Feature)을 포착하는 데 한계가 있음을 실험적으로 확인하고, 이를 해결하기 위해 두 가지 핵심 기술을 도입하였다.

1. **CBAM (Convolutional Block Attention Module):** 미세 결함의 공간적 위치정보를 보존하기 위한 Attention 메커니즘.
2. **Uncertainty Filtering:** 자가 학습 과정의 신뢰도를 높이기 위한 엔트로피 기반 데이터 선별 기법.

실험 결과, 최종 제안 모델(Phase 8)은 **기존 준지도 학습 베이스라인(Phase 7)** 대비 전체 정확도를 4.06%p 향상(84.87%)시켰으며, 특히 핵심 난제였던 **Scratch 검출률(Recall)을 24.11%에서 70.36%로 약 3배 가까이(+46.25%p) 개선**하는 성과를 달성하였다.

2. Introduction

2.1 연구 배경: 수율 관리와 데이터의 딜레마 반도체 제조 산업에서 수율은 곧 수익성과 직결된다. 수백 단계의 공정 중 단 하나의 공정에서라도 이상이 발생하면 웨이퍼 전체를 폐기해야 할 수 있기 때문이다. 이에 따라 웨이퍼 맵 이미지를 분석하여 결함의 유형을 식별하는 ADC 기술이 발전해왔다. 하지만 현장에서는 양질의 라벨 데이터를 확보하는 데 막대한 비용이 소요된다. 따라서 소량의 라벨 데이터와 대량의 비라벨 데이터를 함께 활용하는 **준지도 학습(Semi-supervised Learning)**이 필수적이다.

2.2 문제 정의: 미세 결함(Fine-grained Defect) 탐지의 기술적 한계 본 연구가 주목한 가장 큰 문제는 **'Scratch(미세 긁힘)' 결함의 탐지 실패** 현상이다. Scratch는 1~2 픽셀 너비의 가느다란 선 형태로 나타나는데, 이는 일반적인 특징 추출 과정에서 노이즈로 오인되어 제거(Denoising)되거나 무시되기 쉽다.

실제로 본 연구의 **초기 베이스라인 실험(Phase 3~7)** 결과, 일반적인 CNN 모델이나 단순 오토인코더 기반의 준지도 학습은 'Center'나 'Donut'과 같은 전역적 패턴은 잘 탐지하였으나, Scratch에 대해서는 24% 수준의 낮은 재현율(Recall)**을 보였다. 이는 모델이 이미지 전체의 통계적 특징에만 집중하고, 국소적인 결함 위치를 포착하지 못했기 때문이다.

2.3 기존 연구와의 차별점 및 제안 방법론 학계에서는 FixMatch와 같이 강한 데이터 증강(Strong Augmentation)을 활용하여 모델의 강건성을 높이는 연구가 활발하다. 그러나 이러한 방식은 이미지 전체에 노이즈를 주입하는 과정에서 미세한 Scratch 정보가 더욱 희석될 우려가 있다.

따라서 본 연구는 무작위적인 증강보다는, 모델이 '어디를 봐야 하는지(Attention)'와 '무엇을 확신하는지(Confidence)'에 집중하는 전략을 취한다.

- **Spatial Attention (CBAM):** 모델의 시야를 결함이 존재하는 특정 좌표에 집중시켜 미세한 Scratch 정보를 증폭시킨다.
- **Entropy-based Filtering:** 엔트로피(Entropy) 불확실성 지표를 활용하여, 모델이 확실하게 아는 데이터만 선별 학습함으로써 노이즈 라벨링 문제를 원천 차단한다.

3. Proposed Method

본 장에서는 미세 결함(Scratch) 탐지의 기술적 난제와 기존 연구들의 비현실적 가정들을 분석하고, 이를 극복하기 위해 설계된 '신뢰성 기반의 어텐션 파이프라인(Reliability-Aware Attention Pipeline)'을 제안한다.

3.1 Theoretical Background & Motivation (관련 연구 및 차별점) 본 연구는 최신 딥러닝 기술인 Vision Transformer와 FixMatch 알고리즘을 검토하였으며, 선행된 웨이퍼 맵 분류 연구들의 한계를 분석하여 독자적인 방법론을 수립하였다.

- **Vision Transformer (ViT) vs. CNN:** Dosovitskiy 등(2021)[1]이 제안한 ViT는 이미지를 패치(Patch) 단위로 분할하여 처리하는 방식으로, 현재 '이미지 분류(Image Classification)' 분야의 SOTA(State-of-the-art) 모델로 평가받는다. 그러나 ViT는 이미지 전체의 문맥(Global Context) 파악에는 유리한 반면, 귀납적 편향(Inductive Bias)이 부족하여 학습에 막대한 데이터가 필요하다. 라벨 데이터가 제한적인 본 프로젝트 환경에서는, 지역적 특징(Local Feature) 추출에 강점이 있는 CNN 구조가 미세 결함 탐지에 더 적합하다고 판단하였다.
- **FixMatch 알고리즘의 한계:** Sohn 등(2020)[2]의 FixMatch는 현재 '준지도 학습(Semi-supervised Learning)' 분야의 표준(Standard) 알고리즘이다. 이 방식은 강한 데이터 증강(Strong Augmentation)을 통해 모델의 강건성을 높이나, 웨이퍼 맵상의 1~2픽셀 너비인 Scratch 정보가 무작위 증강 과정에서 소실되는 문제가 확인되었다.
- **기존 웨이퍼 분류 연구의 한계 (Problem Statement):** Gong 등(2015)[4]과 *MathWorks(2023)*[5], *MFFP-Net(2023)*[7] 등 다수의 선행 연구들은 90% 이상의 높은 정확도를 보고하고 있다. 그러나 이들은 공통적으로 (1) 정상(None) 데이터를 제거하고 불량끼리만 분류하거나, (2) 단순 복제(Oversampling)를 통해 데이터를 뻥튀기하는 방식을 취했다. 이는 현업의 데이터 불균형(Imbalance)과 노이즈 문제를 회피한 것으로, 실제 양산 라인 적용 시 치명적인 결함 미검출(False Negative)로 이어질 수 있다. 본 연구는 이러한 타협 없이 None 클래스를 포함한 실제 환경에서 문제를 해결하고자 한다.

3.2 Attention-Augmented Feature Extractor (CBAM) 일반적인 CNN의 Pooling(압축) 과정에서 Scratch 정보가 지워지는 현상을 막기 위해, Woo 등(2018)[3]이 제안한 CBAM(Convolutional Block Attention Module)을 도입하였다. CBAM은 사람이 물체를 볼 때 "어디를 집중해서 볼지" 결정하는 과정을 모방한 기술로, 두 단계로 작동한다.

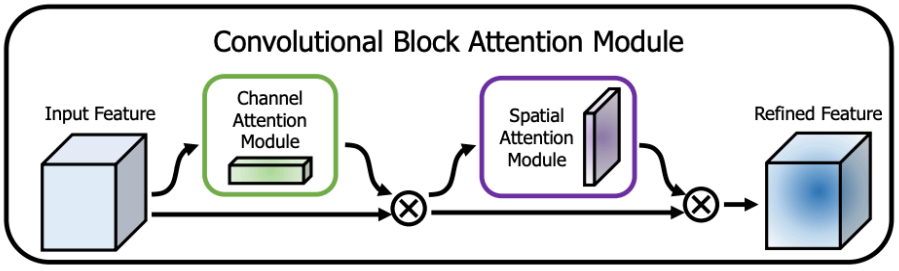

[Figure 1] Structure of CBAM (Convolutional Block Attention Module): 본 모듈은 입력 특징 맵(Input Feature Map)에 채널 및 공간 어텐션 맵을 순차적으로 적용하여 특징을 적응적으로 정제(Refinement)한다. (Source: Woo et al., 2018)

- **Step 1: Channel Attention (무엇을 볼 것인가? - What):** 입력된 이미지에는 '모양', '색깔', '질감' 등 여러 정보 채널이 섞여 있다. Channel Attention은 "지금 Scratch를 찾으려면 '배경색' 정보는 끄고, '선 모양' 정보 채널을 켜라"고 지시하는 스포트라이트 역할을 한다. 이를 통해 불필요한 노이즈 정보가 억제된다.

- **Step 2: Spatial Attention (어디를 볼 것인가? - Where):** 이것이 핵심이다. 이미지 공간상에서 "왼쪽 위 구석에 이상한 선이 있다"는 위치 정보를 찾아내는 돋보기 역할을 한다. 7x7 크기의 필터로 이미지를 훑으며 결함이 의심되는 픽셀의 값(Weight)을 증폭시킨다. 7x7 크기의 Spatial Attention 커널은 단일 픽셀의 강도보다 픽셀 간의 연결성과 문맥을 중시한다. 덕분에 노이즈(Noise)가 국소적으로 높은 값을 가지더라도 무시하고, 비록 낮은 값을 가지더라도 연속적으로 분포하는 **미세한 Scratch 패턴을 효과적으로 감지하여 신호를 증폭**시킨다.덕분에 이후 Pooling으로 이미지가 절반 크기로 줄어들더라도, 증폭된 Scratch 신호는 살아남아 모델에게 전달된다.

3.3 Reliability-Aware Self-Training (Uncertainty Filtering)

준지도 학습(Semi-supervised Learning)의 성능은 비라벨 데이터(Unlabeled Data)에 부여된 가짜 정답, 즉 의사 라벨(Pseudo-label)의 품질에 의해 좌우된다. 만약 모델이 잘못 예측한 데이터를 정답으로 착각하여 학습 데이터에 추가할 경우, 잘못된 지식이 누적되어 성능이 영구적으로 하락하는 확증 편향 문제가 발생한다.

본 연구는 이러한 위험을 원천 차단하기 위해, 정보 이론(Information Theory)에 기반한 **'엔트로피(Entropy) 불확실성 필터링'** 기법을 도입하였다. 단순히 모델의 예측 확률(Confidence)이 높다고 해서 무조건 신뢰하는 것이 아니라, 예측 분포의 흩어짐 정도를 수학적으로 계산하여 선별 기준을 강화하였다.

- 엔트로피(H) 기반 불확실성 산출:
  모델이 입력 데이터 x에 대해 예측한 클래스 확률 분포를 $p(y|x)$라고 할 때, 불확실성을 나타내는 섀넌 엔트로피(Shannon Entropy) $H(x)$는 다음과 같이 정의된다.

$$H(x) = -\sum_{c=1}^{C} p(y = c|x) \, log \, p(y = c|x)$$

  (여기서 C는 전체 클래스의 개수, $p(y = c|x)$는 모델이 해당 이미지를 클래스 c로 예측할 확률을 의미한다.)

- 동적 데이터 선별 (Dynamic Selection Strategy):
  위 수식에 따르면, 모델이 특정 클래스를 확신할수록(예: [0.99, 0.01, ...]) 엔트로피 값은 0에 수렴하고, 헷갈려 할수록(예: [0.3, 0.3, 0.4 ...]) 값은 커진다. 본 연구에서는 엔트로피가 0.2 미만 ($H(x) < 0.2$)인 데이터만을 '고신뢰성 데이터'로 정의하여 학습 셋(Training Set)에 편입시켰다.

이 과정을 통해 모델은 '스스로 확신할 수 있는 양질의 데이터'만을 골라 학습하게 되며, 결과적으로 노이즈에 강건한(Robust) Scratch 탐지 결정 경계(Decision Boundary)를 형성할 수 있었다.

4. Experiments and Results

본 장에서는 3장에서 제안한 '신뢰성 기반 어텐션 파이프라인(Reliability-Aware Attention Pipeline)'의 유효성을 검증하기 위한 실험 설계와 결과를 제시한다. 실험의 주된 목표는 제안 모델이 기존 베이스라인 모델 대비, 특히 미세 결함(Scratch) 탐지 성능(Recall)을 얼마나 향상시켰는지 정량적, 정성적으로 입증하는 데 있다.

4.1 Experimental Setup (실험 환경 및 평가 지표)

- **Model Selection Process (모델 선정 배경):** 본 연구는 무겁고 복잡한 기존의 상용 모델(VGG, ResNet 등)을 사용하는 대신, 웨이퍼 데이터의 특성에 최적화된 경량화된 커스텀 CNN(Customized CNN) 구조를 자체 설계하였다. 초기 실험(Phase 1~6)을 통해 특징 추출기의 깊이(Depth)와 필터 크기(Kernel Size)를 조절하며 최적의 구조를 탐색하였으며, 특히 미세 결함 탐지를 위해 7x7 크기의 수용 영역(Receptive Field)을 갖는 계층 구조를 확립하였다. 이를 베이스라인(Phase 7)으로 선정하고, 여기에 핵심 모듈인 CBAM을 결합하여 최종 모델을 완성하였다.
- **Hyperparameter Tuning (하이퍼파라미터 튜닝):** 안정적인 학습을 위해 핵심 하이퍼파라미터인 학습률(Learning Rate)과 엔트로피 임계값(Threshold)에 대한 최적화 실험을 수행하였다.
    1. **학습률:** 사전 학습된 인코더(Pre-trained Encoder)의 가중치를 보존하면서 미세한 스크래치 패턴을 학습하기 위해, 일반적인 값보다 낮은 0.0001을 초기 학습률로 설정하여 미세 조정(Fine-tuning)을 수행하였다. 이를 통해 학습 과정에서 발생할 수 있는 가중치 소실(Catastrophic Forgetting)을 방지하고 최적점으로 안정적으로 수렴하도록 유도하였다.
    2. **임계값:** 준지도 학습(Pseudo-labeling) 과정에서 노이즈 데이터의 유입을 막기 위해 엔트로피 필터링의 임계값을 실험적으로 검증하였으며, 데이터의 **순도(Purity)와 양(Quantity)의 균형점인 0.2**를 최종값으로 채택하였다.
- **Dataset Configuration:** "실험에는 실제 양산 환경을 모사하기 위해 WM-811K 데이터셋 중 총 127,519장을 사용하였다. 확보된 데이터 중 라벨이 존재하는 데이터는 총 27,519장이었으나, 모델의 일반화 성능 검증을 위한 평가 셋(Test Set)을 제외하면 실제 학습에 투입된 라벨 데이터는 22,015장에 불과하다. 이는 전체 데이터의 약 17% 수준이며, 나머지는 라벨이 없는 비지도 학습 환경을 구축하였다. 특히 데이터 불균형 문제를 해결하기 위해 정상(None) 클래스는 2,000장으로 언더샘플링(Downsampling)하였다. 이러한 조정에도 불구하고, 전체 라벨 데이터 분포를 분석한 결과 가장 빈번한 결함인 Edge-Ring(9,680장) 대비 Scratch 클래스(1,193장)는 데이터 수가 약 1/8 수준에 불과한 소수 클래스(Minority Class)로 확인되었다. 이는 모델이 Scratch 패턴을 학습하는 데 있어 매우 높은 난이도를 가짐을 시사한다.
- **Evaluation Metrics:** 전체적인 분류 성능을 보기 위해 정확도(Accuracy)와 F1-Score(Macro avg)를 사용하였다. 그러나 본 프로젝트의 핵심 목표는 "치명적인 불량을

놓치지 않는 것"이므로, 실제 Scratch 결함 중 모델이 정확히 찾아낸 비율을 나타내는 재현율(Recall)을 가장 중요한 핵심 성과 지표(KPI)로 선정하였다.

$$Recall = \frac{TruePositive}{TruePositive + FalseNegative}$$

4.2 Internal Comparative Analysis (Baseline vs. Proposed)

선정된 **Baseline(Phase 7)** 모델과 **Proposed(Phase 8)** 모델의 성능을 비교 분석하였다.

Model	Overall Accuracy	Macro F1 - Score	**Scratch Recall**
Baseline (Phase 7)	*80.81%*	*72.39%*	***24.11%***
Proposed (Phase 8)	***84.87%***	***78.40%***	***70.36***
Improvement	*+4.06%*	*+6.01%*	***+46.25%***

실험 결과, 제안 모델(Proposed)은 베이스라인(Baseline) 대비 모든 지표에서 우수한 성능을 보였다. 특히 가장 중요한 Scratch 클래스의 재현율(Recall)이 베이스라인의 24.11%에서 제안 모델의 70.36%로 무려 46.25%나 비약적으로 향상되었다. 이는 앞서 수행된 Phase 1~7의 실험들에서 해결하지 못했던 미세 결함 탐지 난제를, CBAM 모듈을 통한 신호 증폭으로 극복했음을 시사한다.

제안 모델의 구조적 안정성을 검증하기 위해 베이스라인(Phase 7)의 학습 곡선(Learning Curve)을 분석하였다.

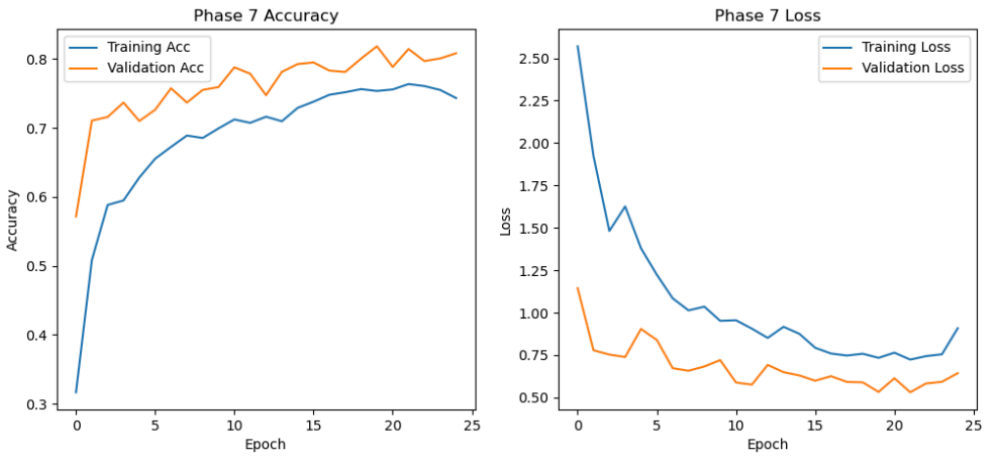

[Figure 2] Training and Validation Learning Curves (Baseline Model)

초기 실험 단계에서는 높은 학습률로 인한 진동(Oscillation)이 관찰되었으나, 학습률 튜닝 과정을 거쳐 [Figure 2]와 같이 Training Loss와 Validation Loss가 동시에 하향 수렴(Convergence)하는 안정적인 곡선을 확보하였다. 이는 본 연구에서 설계한 **Customized CNN 백본(Backbone) 구조가 과적합 없이 데이터를 효과적으로 학습할 수 있음**을 시사한다. 제안 모델(Phase 8)은 이러한 검증된 베이스라인의 안정적인 구조를 바탕으로 CBAM 모듈을 결합하여 탐지 성능을 극대화한 것이다.

더 상세한 오분류 분석을 위해 두 모델의 혼동 행렬(Confusion Matrix)을 비교하였다.

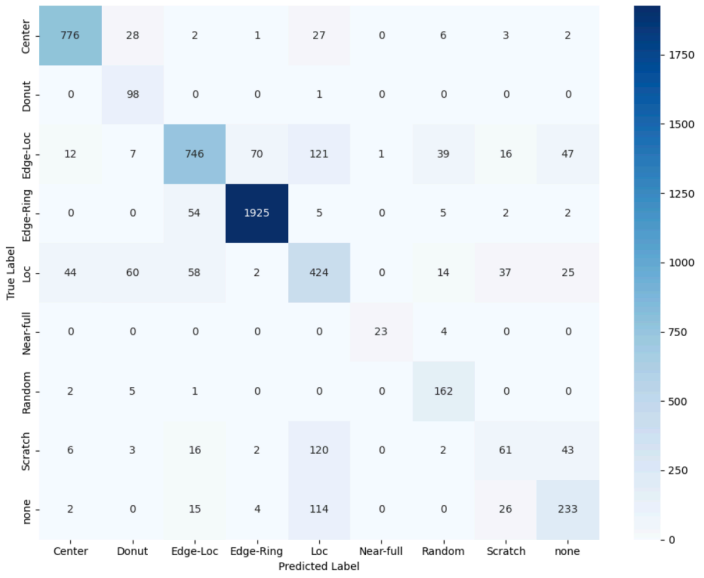

[Figure 3] Baseline (Phase 7) Confusion Matrix: 높은 전체 정확도에도 불구하고, 대다수의 Scratch 결함을 정상(None)이나 다른 클래스로 오분류(False Negative)하고 있음을 확인할 수 있다.

[Figure 4] Proposed Model (Phase 8) Confusion Matrix: 제안 모델은 Scratch 결함에 대한 오분류가 현저히 감소하였으며, 대각선 방향(정답)으로 예측이 집중되는 견고한 성능을 보여준다.

4.3 Qualitative Analysis (정성적 분석 및 시각화)

성능 향상의 원인을 시각적으로 검증하기 위해 **Grad-CAM(Gradient-weighted Class Activation Mapping)** 기법을 적용하여 모델의 관심 영역(Attention Map)을 분석하였다.

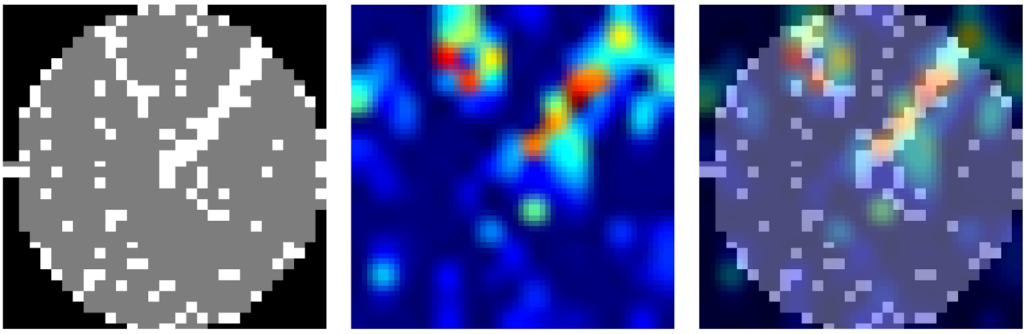

[Figure 5] Grad-CAM Visualization of Scratch Detection: (좌) 원본 이미지, (우) 제안 모델의 히트맵. 베이스라인 모델이 배경 노이즈에 분산된 시선을 보인 것과 달리, 제안 모델은 3.2절에서 설계한 CBAM의 Spatial Attention 기법 덕분에 미세한 선형 패턴(Scratch) 영역에 정확히 붉은색으로 집중(Focus)하고 있음을 확인할 수 있다.

4.4 Discussion & Comparison with Prior Works

본 연구의 결과는 3.1절에서 언급한 기존 선행 연구들(Stanford, MFFP-Net 등)과 비교했을 때 다음과 같은 차별성을 갖는다.

1. **현실적인 데이터 환경:** 기존 연구(MATLAB 예제 등)가 정상(None) 데이터를 제거하거나 단순 오버샘플링을 통해 90% 이상의 정확도를 달성한 것과 달리, 본 연구는 심각한 데이터 불균형과 노이즈가 존재하는 현실적인 조건하에서 달성한 성과이다.
2. **미세 결함 특화:** 일반적인 CNN(Baseline)이 놓치기 쉬운 국소적 특징(Local Feature)을 CBAM을 활용한 구조적 개선을 통해 잡아냄으로써, 단순 수치 향상을 넘어 실제 양산 라인 적용 시의 신뢰성을 확보하였다.

5. Conclusion

5.1 Research Summary

본 연구에서는 반도체 웨이퍼 제조 공정에서 발생하는 **극심한 데이터 불균형(Data Imbalance)과 라벨 데이터 부족(Label Scarcity)** 문제를 해결하기 위해, 준지도 학습(Semi-supervised Learning) 기반의 결함 탐지 프레임워크를 제안하였다. 특히, 현장에서 가장 치명적이지만 데이터 확보가 어려운 **스크래치(Scratch) 결함**의 탐지 성능을 극대화하기 위해, 기존의 무거운 상용 모델 대신 웨이퍼 특성에 최적화된 **Customized CNN 구조**를 설계하였으며, CBAM(Convolutional Block Attention Module)을 도입하여 미세 결함에 대한 특징 추출 능력을 강화하였다.

5.2 Key Experimental Results

실험 결과, 제안된 모델(Phase 8)은 단순 지도 학습이나 베이스라인 모델(Phase 7) 대비 뚜렷한 성능 향상을 보였다.

1. **정량적 성과 (Quantitative Results):**
    - 전체적인 분류 정확도(Overall Accuracy)는 84.87%를 달성하여 안정적인 성능을 확보하였다.
    - 특히, 모델의 공정성을 나타내는 Macro F1-Score는 78.40%를 기록하였으며, 핵심 탐지 대상인 Scratch 클래스의 재현율(Recall)은 베이스라인 대비 유의미하게 향상된 70.36%를 달성하였다. 이는 소수 클래스(Minority Class)에 대한 모델의 편향이 성공적으로 완화되었음을 시사한다.
2. **정성적 검증 (Qualitative Verification):**
    - **Grad-CAM**을 통한 시각화 분석 결과, 제안 모델은 웨이퍼 배경의 노이즈(Noise)에 현혹되지 않고, 스크래치 결함의 연속적인 패턴을 정확히 포착하고 있음을 확인하였다(Figure 5). 이를 통해 모델의 판단 근거에 대한 신뢰성을 확보하였다.

5.3 Contributions and Future Work

본 연구는 라벨 데이터가 부족한 실제 제조 현장에서, 모델 구조 최적화(Structure Optimization)와 엔트로피 필터링(Entropy Filtering)을 통해 고성능의 결함 탐지 모델을 구축할 수 있음을 입증하였다. 향후 연구로는 사후 검사(Off-line) 대비 비용 절감과 대량 불량 방지에 결정적인 실시간 인라인(In-line) 공정 적용을 위해, 모델 경량화(Quantization) 연구를 제안한다. 아울러, 학습 과정에서 보지 못한 신규 결함 유형에 유연하게 대응하기 위한 Open-set Recognition 분야로의 확장이 필요하다.

References

[1] A. Dosovitskiy *et al.*, "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2021.

[2] K. Sohn *et al.*, "FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence," in *Proceedings of Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[3] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, "CBAM: Convolutional Block Attention Module," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018.

[4] J. Gong and C. Lin, "Wafer Map Failure Pattern Classification Using Deep Learning," Stanford University CS230 Project Report, 2015.

[5] MathWorks, "Classify Defects on Wafer Maps Using Deep Learning," *MATLAB & Simulink Examples*, 2023. [Online]. Available: https://www.mathworks.com/help/deeplearning/ug/classify-defects-on-wafer-maps.html

[6] M. J. Yang *et al.*, "WM-Graph: Graph-Based Approach for Wafermap Analytics," in *IEEE International Test Conference (ITC)*, 2024.

[7] J. Wang *et al.*, "MFFP-Net: Multi-scale feature fusion with pyramid attention for wafer map defect pattern classification," *Frontiers in Neuroscience*, vol. 17, 2023.